

MVZV  $F_X(x_1, \dots, x_p) = P(X_1 \leq x_1, \dots, X_p \leq x_p) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_p} f_X(t_1, \dots, t_p) dt_p \dots dt_1$  Verteilungsfunktion  
• Randverteilung:  $f_{X_i}(x) = P(X_i \leq x) \in \text{Bsp: } (X_1, X_2) \cap F_{X_1}(x) = P(X_1 \leq x) = \int_{-\infty}^x f(x_1, x_2) dx_2$  Gemeinsame Dichte von  $X \in X$  p-dim ZV  
• Unabhängigkeit:  $F_X = \prod_{i=1}^p F_{X_i}(x_i) \forall x_i$   
• Bedingt:  $f_X(x|y) = \frac{f_{(X,Y)}(x,y)}{f_Y(y)}$  stetig,  $P(X=x|Y=y) = \frac{P(X=x \wedge Y=y)}{P(Y=y)}$  diskret  $\Leftrightarrow f_X(x)$   $\Leftrightarrow P(X=x)$   $E(X+Y|Z=z) = E(Y|Z=z) + E(X|Z=z)$   
 $E(X|Y=y) = \int x f_X(x|y) dx$  stetig,  $E(X|Y=y) = \sum x_i P(X=x_i|Y=y)$  diskret  $E(X|Y) \in E(X|Y)(w) = E(X|Y=Y(w)) \Rightarrow E(E(X|Y)) = E(X)$ ,  $E(BX+b) = BE(X)+b$ ,  $B$  in  $x_p$  bei  $t_i$  ändern

Varianz  $\text{Cov}(ax+b, cy+cl) = ac \text{Cov}(X, Y)$ ,  $\text{Cov}(X+Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$   $\text{Var}(aX) = a^2 \text{Var}(X)$   $\text{Cov}(X) = E(X^2) - (E(X))^2$  Normalverteilung  $f_X(x) = (\sigma/2\pi)^{-1/2} e^{-x^2/(2\sigma^2)}$   
 $E(X) = (E[X_i])$   
 $\text{Cov}(X) = \Sigma_i (X_i - E(X_i))(X_i - E(X_i))^\top$   $\text{Cor}(X) = \rho(X) = \rho_{ij}$ ,  $\rho_{ij} = \text{Corr}(X_i, X_j) = \text{Cov}(X_i, X_j) / (\sqrt{\text{Var}(X_i)} \sqrt{\text{Var}(X_j)})$  sym  
 $\text{Cov}(BX+b) = B\Sigma_i B^\top$ ,  $\text{Var}(a^T X) = a^T \Sigma_i a$   
• Standardisiert:  $X^* = \left( \frac{x_i - E(X_i)}{\sqrt{\text{Var}(X_i)}} \right) = D^{-1}(X - E(X))$ ,  $D = \text{eye}(\sigma_i)$   
• unabhängig  $X \sim N_p(\mu, \Sigma)$ :  $X_i \sim \mathcal{N}(\mu_i, \Sigma_{ii}) \Leftrightarrow X_i$  unkorreliert  
• Schätzer:  $\hat{X} = \frac{1}{n} \Sigma_i X_i$ ,  $S = \frac{1}{n-1} \Sigma (X_i - \hat{X})(X_i - \hat{X})^\top = (S_{ij})$ ,  $R = (R_{ij}) = (S_{ii}/\sqrt{S_{jj}})$   
□ Verlustfunktion:  $L(y, \hat{f}(x))$ , Trainingsfehler:  $\text{err}(L) = \frac{1}{n} \sum L(y_i, \hat{f}(x_i))$ ; Bsp:  $L = (y - \hat{f}(x))^2$   
Testfehler:  $E(L) = \int [L(y, \hat{f}(x))] f_{X|Y}(x, y) dx dy$

Multi Line Reg.  
□ Modell:  $\hat{Y} = f(X) + \varepsilon = Xb + \varepsilon \Leftrightarrow (\hat{y}_1) = \begin{pmatrix} 1 & x_{11} & x_{1p} \\ 1 & x_{21} & x_{2p} \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{np} \end{pmatrix} \begin{pmatrix} b_0 \\ b_1 \\ \vdots \\ b_p \end{pmatrix} + (\varepsilon_1) \quad \begin{cases} \text{Cov}(\varepsilon_i, \varepsilon_j) = 0 \\ E(\varepsilon_i) = 0 \\ \text{Var}(\varepsilon_i) = \sigma^2 \end{cases} \quad \begin{array}{l} \text{Erklärte Varianz} \\ V(Y)/V(X_i) \in \text{Var der Variable} \end{array}$   
 $\Leftrightarrow \hat{b} = (X^\top X)^{-1} X^\top \hat{y} \quad \Leftrightarrow E(Y|X=x) = b_0 + \sum_{i=1}^p x_{i1} b_i \leftarrow \hat{b}_0 + \sum_{i=1}^p x_{i1} \hat{b}_i = (1, x^\top) \hat{b}$  ist Schätzer  
 $\Leftrightarrow \hat{y} = X\hat{b}$  geschätzte Werte  $\Leftrightarrow \hat{y} = Hy$  mit  $H = X(X^\top X)^{-1} X^\top$  sym hat Matrix  
 $\Leftrightarrow \hat{\varepsilon} = y - \hat{y}$  Residuenvektor  $\Rightarrow SSE = \hat{\varepsilon}^\top \hat{\varepsilon} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$  Residual sum of squares  $\Leftarrow$  wird durch LS min  
 $\Leftrightarrow \hat{\sigma}^2 = \frac{1}{n-(p+1)} \hat{\varepsilon}^\top \hat{\varepsilon} = \frac{1}{n-(p+1)} \sum_{i=1}^n (y_i - \hat{y}_i)^2$  Residual Variance  $\Rightarrow RSE = \sqrt{\hat{\sigma}^2}$  Residual standard error  
 $\Leftrightarrow E(\hat{b}) = b$ ,  $\text{Cov}(\hat{b}) = \sigma^2 (X^\top X)^{-1}$ ,  $E(\hat{\sigma}^2) = \sigma^2$ ,  $E(\hat{\varepsilon}) = 0$   $\Leftarrow$  Approximation:  $\text{Cov}(\hat{b}) = \hat{\sigma}^2 (X^\top X)^{-1}$   
□ VIF =  $1/(1-R_j^2)$  Steigerungsfaktor von  $b_j$  im Vergleich zu  $X_j$  unkorreliert  $\begin{array}{c} \text{unkorreliert} \\ \text{korreliert} \end{array}$   
□ Statistische Testf. Annahme:  $\varepsilon \sim N(0, \sigma^2 I_n)$  verteilt  
 $\Leftrightarrow \hat{b} \sim N_{p+1}(b, \sigma^2 (X^\top X)^{-1}) \rightarrow \hat{b}_j - b_j / \hat{\sigma} + \hat{v}_j \sim N(0, 1)$  mit  $V_j = \text{spur}[(X^\top X)^{-1}]$ .  $R^2$  Anteil der Variabilität der  $y_i$  die durch das Modell erklärt wird

□ Anpassungsgröße  
 $\Leftrightarrow SST = \sum (y_i - \bar{y})^2$  Total sum of squares  
 $\Leftrightarrow SSE = \sum (y_i - \hat{y}_i)^2$  residual sum of squares  
 $\Leftrightarrow SSM = \sum (\hat{y}_i - \bar{y})^2$  model sum of squares  
□ Model parameter [p Korrelationen  $\Rightarrow p+1$  Modellparameter]  
 $\Leftrightarrow AIC = n \log(\frac{1}{n} SSE) + 2(p+1)$   
 $\Leftrightarrow BIC = n \log(\frac{1}{n} SSE) + \log(n)(p+1)$  aus Modell mit allen Kovariaten  
 $\Leftrightarrow (p = SSE/\hat{\sigma}^2 - (n-2(p+1)), \hat{\sigma}^2 \text{ Variansschätzer})$   
□ Variablen Selektion  $\begin{array}{l} \text{subset: alle, wechselweise} \\ \text{Forward: } p=0 \text{ und dann nach best hinzufügen} \\ \text{backward: } p=\text{volll nach best entfernen} \end{array}$

Klassifikation  $X: (\mathbb{R}^{1+1}) \rightarrow \text{RP}$  1G:  $X \rightarrow \{1, \dots, K\}$ ,  $S(X) = \begin{pmatrix} 0 & 1 & \dots & 0 \\ 1 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix}$  Accuracy =  $(TP+TN)/\text{Total}$   
□ Konfusions Matrix  $y = h(x) = \sum_{k=1}^p b_k x_k \leftarrow b_i$  Diskriminanzhöhe  $\Leftrightarrow$  Missclassification Rate =  $(FP+FN)/\text{Total}$   
 $\begin{array}{c|cc} y & k & F \\ \hline T & TP & FN \\ F & FP & TN \end{array}$   $TP = \text{True positive}$ , Fehler 1. Art  $\Leftrightarrow$   $FP = \text{False positive}$ , Fehler 2. Art  $\Leftrightarrow$   $TN = \text{True negative}$ , Fehler 1. Art  $\Leftrightarrow$   $FN = \text{False negative}$ , Fehler 2. Art

Lin Diskriminanz  $[X|Y=k \sim N_p(\mu_k, \Sigma) \quad \forall k=1, \dots, K]$   
□ Annahme: Gemeinsame Kovarianz  $\Sigma$  für Dichten der multivariaten Normalverteilung  
 $\Leftrightarrow \pi_k = n_k/n$   
 $\Leftrightarrow K=2 \quad \Leftrightarrow g(x) > 0 \Leftrightarrow h(x) > 0$   
 $\Leftrightarrow h(x) = x^\top \Sigma^{-1} (\hat{\mu}_1 - \hat{\mu}_0) - \frac{1}{2} (\hat{\mu}_0^\top + \hat{\mu}_1^\top)^\top \Sigma^{-1} (\hat{\mu}_1 - \hat{\mu}_0) + \log(\frac{\pi_1}{\pi_0})$  analog   
 $\Leftrightarrow \text{Quadratisch: } h(x) = \log(\pi_1) - \log(\pi_0) = -\frac{1}{2} \log |\Sigma_1| - \frac{1}{2} (x - \hat{\mu}_0)^\top \Sigma_1^{-1} (x - \hat{\mu}_0) + \log(\pi_1) + \log(\pi_0)$

Multitest	$P = P_{H_0} (T(X_1, \dots, X_n) > T(x_1, \dots, x_n))$	# wahrer $H_0$	V	# Nicht wahr $m_0 - V$	u0	Liniege $\oplus C_i, (C_i)$
$\square FWER = P(V > 0)$	$\square FDR = E(V/\max(R, 1))$	p-werte unabhängig	# falsche $H_0$	R - V	$m_1 - R + V$	Clusterabschneidung angelegt und

Bonferroni:  $p_{Vi} \leq \frac{\alpha}{m}$ ; Sidak:  $p_{Vi} \leq 1 - (1-\alpha)^{\frac{1}{m}}$ ; Holm:  $p_{Vi} \leq \frac{\alpha}{m}$ , p-Werte sortiert,  $m = m-1$  Zentroid

cluster  $d(i,j) = d(j,i); d(i,j) \geq 0; d(i,i) = 0$ : agglomerativ: n cluster  $\rightarrow$  nearest merge ; Single: min  $d(x_i, y_j)$   
k-means: k cluster  $\rightarrow$  d min zuweisen  $\rightarrow$  C  $\rightarrow$  Mittelpunkte neue C  $\rightarrow$  repeat bis no change ; Comp: max  $x_i, y_j d(x_i, y_j)$

PCA |  $\sum_i = \text{Cov}(X) = A \Lambda A^T$ , A normierte EV Ladungsmaatrix,  $\Lambda = \text{diag}(\lambda_i)$   $\lambda_1 \geq \dots \geq \lambda_p \geq 0$  ; Kaiser-Kriterium

$Y = A^T X \Rightarrow Y \geq A^T X$ , Y ist Hauptkomponente zu X

$\text{Cov}(Y_i, Y_j) = 0$ ,  $\text{Var}(Y_i) = \lambda_i$ ,  $\sum_i \text{Var}(Y_i) = \text{spur}(A^T A) = 5$  Gesamtvarianz  $\Rightarrow \lambda_i$  erklärte Varianz

Multi LinReg | Überprüfung der Modellvoraussetzungen

- Modellannahme
- A Ein Zusammenhang zwischen X, Y
- B  $E(\epsilon_i) = 0$ ,  $\text{Var}(\epsilon_i) = \sigma^2$
- C Unkorreliertheit der Fehlerterme
- D Normalverteilung der Fehlerterme
- E Rang(X) = p+1  $\Rightarrow X_j$  lin. unab
- F Multikollinearität

- G  $A + B + C \Rightarrow$  best linear unbiased estimator  $\Rightarrow$  unverzerrte Schätzer
- H Residuenplots sollten keine Struktur aufweisen
- I Verletzungen in A, B, D können durch Transformation behoben werden
- J Verletzung in F können Kovariaten ausgeschlossen werden (PCA)

R-Output | • Multiple R<sup>2</sup>: Anpassungsgröße, wie nahe die Punkte der Geraden sind. Beschreibt die erklärte Varianz und steigt mit der Anzahl an Kovariaten.

- Adjusted R<sup>2</sup>: R<sup>2</sup> von allen statistisch signifikanten Kovariaten
- F-Statistic: model MSE/residual MSE. Test der Nullhypothese, dass alle Parameter 0 sind.

ANOVA	DF	sum squares	mean sum squares	F-Test
Regression (Modell)	p	SSM	SSM/p	
Residuen (Error)	n-(p+1)	SSE	SSE/(n-(p+1))	$F = \frac{SSM/p}{SSE/(n-(p+1))}$
Gesamt (Total)	n-1	SST	SST/(n-1)	

Variable Selektion | Best: min AIC, max R<sup>2</sup>  $\Leftrightarrow$  min SSE

- Subset Selection: Alle Modelle berechnen  $\Rightarrow$  choose best
- Forward Selection: startet mit p=0  $\Rightarrow$  choose best new Kovariate
- Backward Selection: start mit p=voll  $\Rightarrow$  choose worst Kovariate  $\Leftrightarrow$  best model

Diskriminanz

- Bayes-Classifier:  $\pi_k(x) = P(X=k | X=x) = f_k(x) \pi_k / \sum_{l=1}^K f_l(x) \pi_l \Rightarrow \hat{y} = \arg \max_k f_k(x)$
- $f_k(x)$  Schätzer durch  $f_k(x) = \hat{f}_k(x) \cdot I(X=k)$
- Logistische Regression [Y binär {0,1}, X p-dim,  $X, b \in \mathbb{R}^p$ ]  $\Leftrightarrow f(x) = \frac{\exp(b^T x)}{1+\exp(b^T x)}$  logistische Funktion  
 $\Leftrightarrow P(Y=1 | X=x) = \exp(b^T x) / (1 + \exp(b^T x))$ ,  $P(Y=0 | X=x) = 1 / (1 + \exp(b^T x))$  Bsp:  $\exp(b_i) = 1.5 \Rightarrow$  odds für  $Y=1$  vs  $Y=0$  liegt um 50%
- $L(b) = \prod_{i=1}^n P_b(Y_i=k_i | X=x_i)$   $\Leftrightarrow$  Odds(x) =  $\exp(b^T x) \in \exp(b_i)$  relative Veränderung der odds bei Veränderung von Merkmal i

- Diskriminierung
- Güte anhand der Treuehälfte
- Reklassifikationsrate:  $P(Y \neq \hat{Y})$   $\Leftrightarrow$  Sensitivität:  $P(Y=1 | \hat{Y}=1)$   $\Leftrightarrow$  Spezifität:  $P(\hat{Y}=0 | Y=0)$
- positiver prädiktiver Wert:  $P(Y=1 | \hat{Y}=1)$   $\Leftrightarrow$  negativer prädiktiver Wert:  $P(Y=0 | \hat{Y}=0)$

